

Netscape: Yahoo!

Back

Forward

Reload

Home

Search

Netscape

Images

Print

Security

Shop

Stop

N

Location:

http://www.yahoo.com/

[What's Related](#)



Calendar



Messenger



Check Email



YAHOO!



What's New



Personalize



Help

[Y! Messenger](#)

instant messaging

[Yahoo! Mail](#)

free email - you@yahoo.com

Search

[advanced search](#)

Shop

[Auctions](#)

[Autos](#)

[Classifieds](#)

[Shopping](#)

[Travel](#)

[Yellow Pgs](#)

[Maps](#)

Media

[Finance](#)

[Quotes](#)

[News](#)

[Sports](#)

[Weather](#)

Connect

[Careers](#)

[Chat](#)

[Clubs](#)

[GeoCities](#)

[Greetings](#)

[Mail](#)

[Members](#)

[Messenger](#)

[Mobile](#)

[Personals](#)

[People Search](#)

[Photos](#)

Personal

[Addr Book](#)

[Briefcase](#)

[Calendar](#)

[My Yahoo!](#)

[PayDirect](#)

Fun

[Games](#)

[Kids](#)

[Movies](#)

[Music](#)

[Radio](#)

[TV](#)

[more...](#)

[Yahoo! News](#)

Summer School Updates

[Day 5, Vienna: team-08 draws the last slot of the day](#)

[Pneumonia classifier reaches AUC 0.975, looks at the heart](#)

[U-Net segments 392 lesions, blames hair](#)

[Vision-language model writes report for grey square: "benign"](#)

[Clever Hans \(Berlin, 1904\) still undefeated in arithmetic](#)

[Audience: coffee supplies "critical", organisers "monitoring"](#)

Sources: team-08, SageMaker, Bedrock



[Arts & Humanities](#)

Literature, Photography...

[Business & Economy](#)

B2B, Finance, Shopping, Jobs...

[Computers & Internet](#)

Internet, WWW, Software, Games...

[Education](#)

College and University, K-12...

[Health](#)

Medicine, Diseases, Drugs, Fitness...

[News & Media](#)

Full Coverage, Newspapers, TV...

[Recreation & Sports](#)

Sports, Travel, Autos, Outdoors...

[Reference](#)

Libraries, Dictionaries, Quotations...

[Regional](#)

Countries, Regions, US States...

[Science](#)

Animals, Astronomy, Engineering...

[In the News](#)

[Heat maps fail sanity check](#),
random weights look the same

[Model explains itself](#) - reason not
real

Live coverage: [Hörsaal](#) | [Audio](#)

[more...](#)

[Marketplace](#)

[Y! Real Estate](#) - [rent a GPU](#)

[Y! Careers](#) - prompt engineer, no
formulas

[Bill Pay](#) - Bedrock invoice online

[Broadcast Events](#)

[AI4Imaging Summer School](#) - live
on [FinanceVision](#)

[more...](#)

[Inside Yahoo!](#)

[Play free Fantasy Football](#)

[Make Yahoo! your home page](#)

Document: Done

1



Explainability:

Warum sagt das Modell das?

Drei Fragen, drei Modelle, eine Regel:
Jede Erklärung wird gegen eine Kontrolle getestet.

team-08 · AI4Imaging Summer School 2026 · Vienna

Drei Fragen, drei Modelle, eine Regel

Tag 1 · Klassifikator

Wo hat es hingeschaut?

Grad-CAM · Saliency · Integrated Gradients

Kontrollen: Zufallsgewichte, eine Lungenmaske

Tag 2 · U-Net

Wo irrt es, und weiß es das?

Fehlerkarten · Test-Time-Augmentation

Kontrollen: die schlechtesten Fälle, das gespiegelte Bild

Tag 2 · VLM

Warum sagt es das, und ist der Grund echt?

Befunde von Qwen3-VL


Kontrollen: anderer Prompt, anderer Patient, kein Bild



*1904: Ein Pferd namens Kluger Hans konnte rechnen. Es hat im Gesicht des Fragestellers gelesen.
Jedes Modell, das wir trainiert haben, ist ein möglicher Kluger Hans. Die Aufgabe ist, das Gesicht zu finden.*

Hans & Wilhelm von Osten, c. 1904 (public domain)

Wo hat es hingeschaut?





ResNet18 auf PneumoniaMNIST, 28×28 Pixel. Vier Fälle, drei Methoden: eine richtig erkannte Pneumonie, ein richtig erkanntes Normalbild, ein Normalbild als krank, eine übersehene Pneumonie.

Test-AUC **0,975**

Grad-CAM auf **layer2**, Raster **7×7**, hochskaliert auf 28×28
Saliency und Integrated Gradients: pro Pixel, scharf aber verrauscht

Die Heatmap lügt nicht. Sie sagt nur wenig.

Schaut es auf die Lunge?




Grad-CAM-Masse in der Lunge	0,34
Lungenanteil am Bild, ein Zufallsblick	0,35
Zufallsgewichte	0,22
heißester Pixel in der Lunge	23 % von 624 Bildern

Wo ist die Lunge? Das sagt ein zweites Modell: ein U-Net (ResNet34-Encoder), trainiert auf 138 öffentlichen Thorax-Röntgenbildern mit handgezeichneten Lungenmasken (Montgomery, Val-Dice 0,98). Grün: seine Lungenkontur.


Ein guter Messerwerfer verfehlt mit Absicht. Unser Klassifikator verfehlt die Lunge aus Zufall.

Der Placebo-Test für Heatmaps



Gleiche Bilder, gleiche Schicht, gleiche Methode. Oben: trainiert. Unten: alle Gewichte neu gewürfelt. Mittlere Korrelation der Karten $-0,03$ (je Fall 0,00 / $-0,47$ / 0,17 / 0,19) · Adebayo et al. 2018


Wo irrt es?



392 Testbilder. Die drei schlechtesten, links: Haare · die Annotation umrandet die ganze Glasplatte · kein Kontrast. Grün richtig, rot zu viel, blau übersehen.

Dice im Mittel 0,897. Im Mittelwert verstecken sich die 22 Fehler.

Weiß es, wann es falsch liegt?



Dieselben sechs Bilder. Mittlere Reihe: Mittel aus vier gespiegelten Durchläufen. Untere Reihe: wo sich die vier uneinig sind, hell = Uneinigkeit, cyan = Referenzkontur. Über 392 Bilder, Uneinigkeit gegen Dice: Spearman $\rho = -0,36$.

Wo sich die vier Antworten unterscheiden, sitzen die Fehler. Der Haar-Fleck leuchtet. Die falsche Annotation nicht.

Warum sagt es das?

Same image, same model, five prompts: what the VLM calls it
(green = matches histology, red = does not, grey = no label found)

ISIC_0002469 (histology: Benign)	Benign	Benign	Benign	Benign	Benign
ISIC_0014274 (histology: Benign)	Malignant	Malignant	Malignant	Malignant	Benign
ISIC_0012744 (histology: Benign)	Malignant	Benign	Malignant	Malignant	Benign
ISIC_0012455 (histology: Benign)	Malignant	Malignant	Malignant	Malignant	Malignant
ISIC_0013975 (histology: Malignant)	Malignant	Malignant	Malignant	Malignant	Benign
ISIC_0013618 (histology: Malignant)	Malignant	Malignant	Malignant	Malignant	Benign
ISIC_0014324 (histology: Malignant)	Malignant	Malignant	Malignant	Malignant	Benign
ISIC_0000043 (histology: Malignant)	Malignant	Malignant	Malignant	Malignant	Malignant
	naive	few_shot	chain_of_thought	structured_output	combined

Dermoscopic Examination Report

Patient ID: [Redacted]

Date of Examination: [Redacted]

Anatomic Site: [Not specified ...]

der "naive" Prompt, wörtlich · 6 von 8
Befunden sehen so aus

Qwen3-VL · acht Testbilder, vier benigne, vier Melanome · nur die Anweisung ändert sich · grün: stimmt mit der Histologie überein

Gleiche Pixel, fünf Prompts: 5 von 8 Bildern wechseln ihr Label. Der Prompt entscheidet, nicht das Bild.

Gleiche Pixel, anderer Patient

16 von 16

Antworten: **maligne**.

Zwei Melanome, je vier Patienten:

Original · 25 Jahre · 75 Jahre · keine Metadaten.

25 Jahre: "Spitz nevus in young female is possible but cannot be ruled out clinically."

75 Jahre: "High risk for melanoma given **age**, size, and dermoscopic atypia."

Original: "asymmetry in **elderly** patient."


Chain-of-Thought-Begründung zum selben Bild, wörtlich

Das Urteil hat sich nie bewegt. Die Begründung hat sich darum herum neu geschrieben.

Die Farbe des Nichts

The colour of nothing: one flat square, same prompt and metadata as the melanoma, what the VLM calls it

	ISIC_0013975 (age 80, female, site Head and neck)	ISIC_0013618 (age 65, male, site Trunk)
grey (reference)	benign / reassure conf low	benign / reassure conf low
black	benign / reassure conf low	benign / reassure conf low
white	benign / reassure conf low	benign / reassure conf low
skin	benign / reassure conf low	benign / reassure conf low
light brown	suspicious / excision conf low	benign / reassure conf low
dark brown	benign / reassure conf low	benign / reassure conf low
red	suspicious / excision conf low	suspicious / excision conf low



```
"image_quality":  
"poor",  
"structures": [],  
"impression":  
"benign",  
"recommendation":  
"reassure"
```

der Prompt des Melanoms
auf einem grauen Quadrat

Sieben einfarbige Quadrate, gleicher Prompt und gleiche Metadaten wie bei den zwei Melanomen. Jede Antwort sagt "Bildqualität schlecht", "Sicherheit niedrig".

Nichts zu sehen: 10 von 14 Mal "benigne, beruhigen". Rot: Operation.

Was wir mitnehmen



1. **Eine Karte ist kein Beweis.** Die Kontrolle gehört dazu: Zufallsgewichte, eine Lungenmaske, ein anderer Prompt, ein anderer Patient, kein Bild.
2. **Bei Segmentierung Fehler messen,** statt Heatmaps zu bewundern.
3. **Eine flüssige Begründung ist die gefährlichste Erklärung von allen.**

Anhang

Drei weitere Kontrollen, für die Diskussion.

Trennt es die Klassen im Inneren?

Features of layer2, test set



128 Merkmale aus layer2 pro Bild, auf zwei Dimensionen gepresst. PCA: 63 % der Varianz in zwei Achsen. Wo sich die Wolken überlappen, wohnen die Fehler.

Gleiche Pixel, acht Modelle

Same 8 images, same prompt (structured_output), different models: what each VLM calls it
(green = matches histology, red = does not, grey = no label found)

	ISIC_0002469 (Benign)	ISIC_0012455 (Benign)	ISIC_0012744 (Benign)	ISIC_0014274 (Benign)	ISIC_0000043 (Malignant)	ISIC_0013618 (Malignant)	ISIC_0013975 (Malignant)	ISIC_0014324 (Malignant)
Qwen3-VL 235B (Referenz) [5/8]	Benign	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant
Claude Sonnet 5 [4/8]	Benign	Malignant	Benign	Benign	Benign	Benign	Benign	Malignant
Claude Haiku 4.5 [5/8]	Benign	Malignant	Benign	Malignant	Malignant	Malignant	Benign	Malignant
Amazon Nova Pro [4/8]	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant
Mistral Pixtral Large [4/8]	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant	Malignant
Gemma 3 27B [5/8]	Malignant	Malignant	Benign	Benign	Malignant	Benign	Malignant	Malignant
GPT-6 Astra [5/8]	Benign	Benign	Malignant	Malignant	Benign	Malignant	Malignant	Malignant
Grok 4.6 [2/8]	Malignant	Malignant	Malignant	Malignant	Benign	Malignant	Malignant	Benign

ISIC_0002469, benign, age 15,
differential:

Haiku 4.5: "dermatofibroma"

Sonnet 5: "café-au-lait macule"

GPT-6: "Spitz nevus"

Gemma 3: "melanoma in situ"

Pixtral: "melanoma, Reed nevus"

gleiches Bild, gleicher Prompt · fünf Modelle,
fünf Krankheiten


"impression": "benign",
"recommendation": "excision"

Sonnet 5 bei ISIC_0000043, einem Melanom:
harmlos, aber bitte herausschneiden

Dieselben 8 Bilder und derselbe strukturierte Prompt wie vorhin, nur das Modell ändert sich · bester Wert **5 von 8**, kein Modell schlägt Qwen · **8 von 8** Bildern bekommen je nach Modell widersprüchliche Labels · Nova, Pixtral und Grok nennen alle vier benignen Läsionen maligne, Sonnet 5 drei von vier Melanomen benigne · Mehrheitsvotum: 5 von 8

Acht Zweitmeinungen. Keine davon ist eine Zweitmeinung über das Bild; jede ist eine Erstmeinung über ihre eigenen Trainingsdaten.

Wer stimmt mit wem überein?



Breite des Bands: Zahl der 8 Bilder, bei denen zwei Modelle dasselbe Label geben. Bogenlänge: wie oft ein Modell überhaupt mit den anderen übereinstimmt.

Nova Pro · Pixtral: 8 of 8
Qwen · Pixtral: 7 of 8
Qwen · Nova Pro: 7 of 8

die drei engsten Paare sind die drei Modelle, die zu fast allem "maligne" sagen

Sonnet 5 · Pixtral: 2 of 8
Sonnet 5 · Nova Pro: 2 of 8

das einsamste Modell ist das, das untertreibt

run 2 → run 3, same settings:
Sonnet 5 5/8 → 4/8 · Nova 5/8 → 4/8
majority vote 6/8 → 5/8

wir haben es zweimal laufen lassen · zwei Modelle änderten ihren Wert, ohne dass sich etwas geändert hätte

Am meisten einig sind sich die Modelle, die zu allem "maligne" sagen. Einigkeit ist nicht Richtigkeit.

