

Sprechernotizen (Deutsch)

Erzeugt aus presentation.html (17 Folien inkl. Gag und Anhang). Pro Folie: Kicker, Titel, Pointe auf der Folie, Notizen. Anhang-Folien und die beiden Gag-Folien sind ungezählt.

Gag · Netscape: Yahoo!

(keine Notizen)

Folie 1 · Explainability: / Warum sagt das Modell das?

- Zwei Tage, **drei Modelle**: Pneumonie-Klassifikator, Segmentierung Hautläsion, VLM schreibt Befunde
 - Jedes gibt **eine Antwort**, keines **einen Grund**
 - Vortrag: wie wir den Grund herausgeholt haben
 - ... und wie oft er sich als **Illusion** entpuppt hat
-

Folie 2 · Drei Fragen, drei Modelle, eine Regel

Überblick

1904: Ein Pferd namens Kluger Hans konnte rechnen. Es hat im Gesicht des Fragestellers gelesen. / Jedes Modell, das wir trainiert haben, ist ein möglicher Kluger Hans. Die Aufgabe ist, das Gesicht zu finden.

- Kluger Hans 1904: rechnet nicht, liest das Gesicht → jedes Modell ein möglicher Hans
- Explainability ≠ eine Methode; Frage hängt von der Ausgabe ab
- Label → „**Wo?**“
- Maske → „**Wo liegt es falsch?**“
- Text → „**Warum?**“ = schwerste Frage: Modell liefert bereitwillig ein Warum ohne Bezug zur Entscheidung
- Regel heute: jede Erklärung + **Kontrolle** (etwas ändern oder wegnehmen → **überlebt** die Erklärung?)

Folie 3 · Wo hat es hingeschaut?

Tag 1 · Klassifikator

Die Heatmap lügt nicht. Sie sagt nur wenig.

- Vier Bilder v. l. n. r.: Pneumonie richtig (TP), Normal richtig (TN), Normal → „krank“ (FP), Pneumonie übersehen (FN)
- **Grad-CAM**: letzter Faltungsblock mit Raster, hochskaliert
- **Saliency**: jeder Pixel → wie stark bewegt er die Ausgabe; scharf, verrauscht
- **Integrated Gradients**: Saliency gemittelt über den Weg vom schwarzen Bild
- Einig? **Nur grob**
- Grad-CAM **bleibt im Thorax**: TP rechte Lunge + linkes Unterfeld, FN linkes Oberfeld; **Bildrand leuchtet nie**
- Lunge oder Thorax als Ganzes? → nächste Folie
- Saliency / IG bei 28 px: **Salz und Pfeffer**, grob Mediastinum und Hili, keine Region für die Radiologin
- Merksatz: Genauigkeit der Heatmap **begrenzt durch die Schicht**, nicht durch die Krankheit

Folie 4 · Schaut es auf die Lunge?

Tag 1 · Klassifikator

Ein guter Messerwerfer verfehlt mit Absicht. Unser Klassifikator verfehlt die Lunge aus Zufall.

- Heatmap allein kennt keine „richtige Stelle“ → braucht Definition
- Definition: **U-Net segmentiert die Lunge**; Maß = Anteil der Wärme in der Maske
- **1/3 der Aufmerksamkeit auf der Lunge**, 1/3 des Bildes ist Lunge → **Zufallsniveau**
- Zufallsnetz schlechter → Training hat den Blick bewegt, aber nicht in die Lungenfelder
- TN und FP: Wärme auf **Mediastinum und Herz**
- Heißester Pixel in der Lunge: **23 % von 624 Bildern**
- Bei 28 px gelernt: **Form und Helligkeit des Thorax**, nicht das Infiltrat
- Ehrlichkeit: Lungenmaske selbst ein Modell, **Dice 0,76** vs. unabhängiger Segmentierer → Mittelwert, kein Urteil pro Bild

Folie 5 · Der Placebo-Test für Heatmaps

Tag 1 · Klassifikator

- **Adebayo et al. 2018**: alles Gelernte zerstören → ändert sich die Erklärung? Bei beliebten Methoden kaum
- Unser Test: trainiertes Netz vs. Zufallsgewichte, Korrelation der Karten
- Korrelation **nahe 1** = Karte folgt den Bildkanten, nicht dem Gelernten
- **Nahe 0** = trainiertes Modell schaut wirklich irgendwo Bestimmtes hin
- Ergebnis: mittlere Korrelation **-0,03 → Kontrolle bestanden**
- Zufallsnetz malt den Bildrand (links, unten) bei Normal und FN; flache Karte beim TP
- Trainiertes Modell: **nie auf den Rand**
- Diese Kontrolle immer, bevor eine Heatmap zur Ärztin geht

Folie 6 · Wo irrt es?

Tag 2 · U-Net · Kontrolle: die schlechtesten Fälle ansehen

Dice im Mittel 0,897. Im Mittelwert verstecken sich die 22 Fehler.

- Segmentierung: **keine Heatmap nötig**, Vorhersage ist schon ein Bild → ehrliche Erklärung = **Fehlerkarte**
- Kontrolle: nicht der Mittelwert, die **schlechtesten Fälle**
- Dice Mittel **0,897**, Median 0,932; **22 von 392 unter 0,7**
- Drei schlechteste = drei Geschichten:
- Links: **Haare** → dunkles Gewirr als Läsion gemalt
- Mitte: Annotation umrandet die ganze Glasauflage → **Referenz falsch**, nicht das Modell
- Rechts: **blasse Läsion**, kaum Kontrast → nur der dunkle Kern gefunden
- Modell irrt nicht zufällig, sondern **bei einem Bildtyp**
- (Wenn Zeit) Kopf/Hals Dice **0,83 vs. 0,92** Rumpf – dort sind die Haare

Folie 7 · Weiß es, wann es falsch liegt?

Tag 2 · U-Net · Kontrolle: das Bild spiegeln

Wo sich die vier Antworten unterscheiden, sitzen die Fehler. Der Haar-Fleck leuchtet. Die falsche Annotation nicht.

- Gleiche Frage viermal: Bild **viermal gespiegelt**, kein neues Training, vier Durchläufe
- Karte: **hell = die vier Antworten widersprechen sich**
- Haar-Fall links: falsch-positiver Fleck **leuchtet** → gemalt, aber unsicher
- Glasplatten-Fall: **dunkel** → Modell sicher; falsch ist die Annotation → Uneinigkeit erkennt das **nicht**
- 392 Testbilder: Korrelation Uneinigkeit–Dice **–0,36**
- Modell weiß ungefähr, wann es auf **dünnem Eis** ist
- Nicht kalibriert, keine Wahrscheinlichkeit, aber **kostenlos**

Folie 8 · Warum sagt es das?

Tag 2 · VLM · Kontrolle: den Prompt ändern

Gleiche Pixel, fünf Prompts: 5 von 8 Bildern wechseln ihr Label. Der Prompt entscheidet, nicht das Bild.

- Sprachmodell liefert die Begründung gratis
- Kontrolle: **Pixel behalten, Prompt ändern**, fünfmal
- Muster 1: Modell **schlägt zu oft Alarm** – 3 der 4 benignen unter fast jedem Prompt „maligne“
- Muster 2: **„combined“** (Few-Shot + CoT + JSON) macht das Gegenteil: **3 der 4 Melanome benigne**
- Warum? Few-Shot-Beispiel A = harmloser Nävus → „Melanocytic nevus“ in **6 von 8** Befunden
- Ein Melanom: Beispiel A fast **Feld für Feld abgeschrieben** (symmetrisch, regelmäßiger Rand, beruhigen, Sicherheit hoch)
- Keine Sätze kopiert – **die Antwort kopiert**
- Naiver Prompt: statt Befund ein **leeres Formular**, Feld „Patientenname“ in 6 von 8
- Welche der fünf ist die Erklärung? **Keine** – fünf Geschichten über dieselben Pixel

Folie 9 · Gleiche Pixel, anderer Patient

Tag 2 · VLM · Kontrolle: den Patienten ändern

Das Urteil hat sich nie bewegt. Die Begründung hat sich darum herum neu geschrieben.

- Sprachmodell nicht zu öffnen → **eine Eingabe ändern**, zuschauen
- Zwei Melanome, Pixel gleich; Patient **25 / 75 / keine Angabe**
- CoT + strukturiert × 2 Melanome × 4 Varianten = **16 Antworten**
- Urteil **nie bewegt: 16 von 16 maligne** → bestandene Kontrolle, so berichten wir sie
- Aber die Begründung bewegt sich: bei 25 **Spitz-Nävus**, bei 75 **Alter als Risikofaktor**
- Begründung wird **um die Antwort herum gebaut**, nicht umgekehrt

Folie 10 · Die Farbe des Nichts

Tag 2 · VLM · Kontrolle: das Bild wegnehmen

Nichts zu sehen: 10 von 14 Mal "benigne, beruhigen". Rot: Operation.

- Letzte Kontrolle: **Bild wegnehmen** – graues Quadrat + klinischer Kontext des Melanoms
- Antwort: Qualität schlecht, keine Strukturen, keine Farben ... Beurteilung **benigne**, Empfehlung **beruhigen**
- Antwort auf Nichts oder nur auf Grau? → **sieben Farben**
- Grau, Schwarz, Weiß, Haut, Dunkelbraun: benigne, beruhigen, jedes Mal
- **Rot: verdächtig, Exzision** – DD amelanotisches Melanom, Angiom, Basaliom; trotz „keine Strukturen, niedrige Sicherheit“
- **Hellbraun**: verdächtig bei 80-jähriger Frau am Kopf, benigne bei 65-jährigem Mann am Rumpf → **Metadaten kippen das Urteil**
- Echte Läsionen: Alter bewegt nie; leeres Bild: der Prompt ist alles, was das Modell hat
- Nichts sehen und „harmlos“ sagen = **gefährlichste Standardantwort** der Dermatologie
- 14 Aufrufe, etwa eine Minute

Folie 11 · Was wir mitnehmen

Tag 1 + Tag 2

- **Ghassemi, Oakden-Rayner, Beam**: erklärbare KI in der Medizin = „falsche Hoffnung“
- Nicht weil die Methoden nutzlos wären, sondern weil sie **ohne Kontrollen** gezeigt werden
- Jede unserer Kontrollen: **Minuten**
- Danke

Anhang · Anhang

(keine Notizen)

Anhang · Trennt es die Klassen im Inneren?

Anhang · Tag 1 · Klassifikator

- Globale Sicht: **zwei Wolken**, normal links, Pneumonie rechts
 - Dazwischen **gemischtes Band** = falsch Positive und Negative
 - Modell hat intern eine Vorstellung von zwei Klassen
-

Anhang · Gleiche Pixel, acht Modelle

Anhang · Tag 2 · VLM · Kontrolle: das Modell tauschen

Acht Zweitmeinungen. Keine davon ist eine Zweitmeinung über das Bild; jede ist eine Erstmeinung über ihre eigenen Trainingsdaten.

- Qwen-Problem? Gleiche 8 Bilder, gleicher strukturierter Prompt, **7 weitere Modelle** auf Bedrock
- Keines über **5 von 8**; die Fehler sind **nicht dieselben**
- Nova, Pixtral, Grok: **jede benigne Läsion maligne**
- Sonnet 5: Gegenteil, **3 der 4 Melanome benigne**; einmal „impression benign“ + „recommendation excision“ im selben JSON
- Fehler in verschiedene Richtungen → **Mehrheitsvotum nicht besser** als bestes Einzelmodell
- Für Explainability: Label **keine Eigenschaft der Pixel** – alle 8 Bilder wechseln das Label, wenn nur das Modell wechselt
- DD für den Nävus der 15-Jährigen: **5 Modelle, 5 Krankheiten** (Dermatofibrom ... Melanoma in situ), gleicher ruhiger Ton
- Modellwahl = **versteckter Hyperparameter** der Erklärung

Anhang · Wer stimmt mit wem überein?

Anhang · Tag 2 · VLM · Kontrolle: zweimal fragen

Am meisten einig sind sich die Modelle, die zu allem "maligne" sagen. Einigkeit ist nicht Richtigkeit.

- Gleiche Daten als Chord-Diagramm: breites Band = gleiches Label bei vielen der 8 Bilder
- Breitesten Bänder: **Nova Pro, Pixtral, Qwen** – 7 oder 8 von 8
- Grund: sagen zu fast allem maligne → wer immer dasselbe sagt, stimmt immer überein = **gemeinsamer Bias**, keine Einsicht
- Sonnet 5 am anderen Ende: einig bei 2 Bildern, irrt in die Gegenrichtung
- Komitee mittelt nicht die Fehler heraus, sondern **die Verzerrungen**
- Kasten unten: alles **zweimal** mit identischen Einstellungen → Sonnet 5 und Nova je 1 Treffer verloren, Mehrheit **6 → 5**
- Erklärung, die sich beim Nachfragen ändert, war nie Erklärung des Bildes: **eine Stichprobe**

Anhang ·

(keine Notizen)